

04/02/2021 - Latences importantes réservation et mise à jour des données en temps réel impossible

Résumé

Deux problèmes se sont succédés dans la matinée du 04/02/2021

- Le service de réservation était partiellement indisponible, aussi bien pour les utilisateurs (depuis l'app mobile ou le site web) que pour les partenaires (depuis le portail)
- Les données en temps réel n'étaient pas mises à jour malgré les remontées de données issues des capteurs.

Timeline

Intervenants :

- Micaël Pais Novo (MPN)
- Raphaël Galmiche (RG)
- Juliette Gorline (JG)
- Rémi Bruyère (RB)


Timestamp	Évènement
2021-02-04 08:20	Le support reçoit un grand nombre de signalements concernant des lenteurs sur l'interface d'administration pour gérer les réservations.
2021-02-04 08:22	MPN constate le dysfonctionnement sur le site web et le portail. Il constate que les autres services ne semblent pas impactés. Il lance des recherches en vérifiant l'état de santé de la base de données, du service interne de réservation et de l'API de réservation
2021-02-04 08:28	Plusieurs logs sur l'API de réservation mentionnent une connexion défaillante entre l'API et le service interne. La piste d'un problème réseau est privilégiée.
2021-02-04 08:31	Réservation API et réservation service sont redémarrés plusieurs fois. Aucune amélioration significative n'est constatée.
2021-02-04 08:41	Après de nouvelles recherches, la piste réseau est écartée. Dans le même temps, RG signale que reservations-service crash à cause d'un problème mémoire
2021-02-04 08:47	MPN rollback le reservations-api sur une version antérieure (2.1.4.1). Cette version ne s'appuie pas sur reservation-service pour afficher les disponibilités. Le rollback permet de débloquent l'interface publique.

2021-02-04 08:58	JG signale que des milliers de messages non traités s'accumulent sur la file d'attente "dataProcessing" de Rabbitmq. Au même moment, RB signale que les données en temps réel ne sont plus mises à jour depuis 08:10 UTC. Il redémarre les workers temps réel. Cela ne permet pas de débloquer la situation
2021-02-04 09:10	MPN redémarre rabbitmq pour purger les messages qui s'accumulent et voir si les workers sont à nouveau capables de traiter les messages. Cela ne permet pas de débloquer la situation.
2021-02-04 09:22	Un blocage est identifié au niveau du service sites. RB redémarre le service. Quelques instants plus tard, les données en temps réel se mettent à jour correctement. Les messages sont dépilés normalement sur rabbitmq. Tous les services sont opérationnels.


Origine

L'origine précise du problème n'est pas encore précisément identifiée . Plusieurs éléments sont cependant notables et permettront de mener des recherches approfondies

Bien que les premiers signalement d'un ralentissement aient eu lieu à 08:20 UTC, plusieurs indicateurs montrent que le problème a certainement commencé à 08:10 UTC




Nombre de requêtes sur le sites-service par minute. On observe une chute brutale du nombre de requêtes à partir de 08:10 UTC et un volume de requêtes plus faible par rapport à l'accoutumée entre 08:10 UTC et 09:22 UTC (malgré quelques pics)



Nombre de connexions ouvertes à la base de données primaire du cluster. On observe une augmentation du nombre de connexions actives à partir de 08:10 UTC.

Aucune opération particulière n'était pourtant en cours à 08:10 UTC. Les indicateurs de charge des différents composants (noeuds docker, bases de données, ...) n'indiquent pas de goulot d'étranglement



Charge CPU du nœud principal du cluster de base de données. Aucun pic anormal n'est observé

La première cause envisagée était un problème de connectivité induit pas le log suivant sur l'API de réservation :

```
[{"message":"request to  
http://reservations-service_reservations-service/graphql failed, reason:  
socket hang  
up", "type":"system", "errno":"ECONNRESET", "code":"ECONNRESET"}]
```

Ce problème n'étant pas généralisé à d'autres services, nous avons abandonné cette piste.

Nous avons ensuite pensé que le service de réservation était en cause. C'est pourquoi nous avons rollback l'api réservation sur une version antérieure qui n'utilise pas le service pour afficher les disponibilités. Cette action a permis de débloquent le problème de latence rencontré depuis 08:10 UTC.


Cependant, quelques minutes plus tard, l'arrêt de la mise à jour des données en temps réel (depuis 08:10 UTC également) nous a amené à penser que le problème a été finalement provoqué par un dysfonctionnement sur sites-service qui ne répondait plus aux requêtes faites par d'autres composants. Un redémarrage de ce dernier a permis de rétablir le fonctionnement des workers temps réel et de tous les composants qui en sont dépendants (reservations-service, stats-service, ...)

Les ralentissements sur le service de réservation (par l'intermédiaire de reservations-service) et l'arrêt de la mise à jour des données en temps réel ont donc été provoqués par un dysfonctionnement de sites-service.

Résolution et reprise d'activité


Un redémarrage de sites-service a permis de solutionner les différents blocages.

Quelques heures plus tard, nous avons observé un épisode similaire (bien moins important) entre 11:38 UTC et 12:02 UTC avec des ralentissements constatés sur la data-api, l'api de réservation ou stats-service. Tous utilisent (directement ou non) sites-service qui a montré de nouveau un comportement inhabituel pendant cette période



Nombre de requêtes sur le sites-service par minute. On observe une nouvelle chute brutale du nombre de requêtes à partir de 11:38 UTC.

Cet épisode semble coïncider avec un double crash sur le cluster de bases de données de production. Ces crashes ont été occasionnés par un bug de sécurité déjà rencontré ([#32045681](#)).



Nombre de connexions sur le cluster de bases de données. On observe deux chutes du nombre de connexions sur l'interface RW (interface sur le noeud principal) à 11:38 UTC et 11:40 UTC

Un redémarrage de sites-services a permis à nouveau de solutionner le problème de latence.

En attendant de trouver une explication, nous avons rollback la version de sites-service 1.0.2. La dernière version (1.0.5) a été développée suite à l'incident du 01/02/2021. Elle s'appuyait sur l'interface RO du router mysql pour les opérations de lecture dans le but d'étaler la charge sur plusieurs machines.

Mesures correctives et préventives

Aucune mesure corrective (à part le rollback de sites-service) n'a été mise en place à ce jour. D'avantage d'investigations sont nécessaires pour comprendre l'origine exacte du problème afin de le solutionner.

Une hypothèse semble cependant probable : les drivers mysql pour Node.js écartent un nœud du pool de connexions après un certain nombre de tentatives de connexions échouées. Ce comportement peut potentiellement entraîner la mise à l'écart du nœud principal responsable des écritures. Sans cette connexion, le service ne peut fonctionner correctement. Quelques tests peuvent être menés sur un environnement dédié pour valider cette hypothèse. Par exemple :

- Ajouter des logs sur les événements de connexion et déconnexion au niveau du driver mysql.
- Simuler un ou plusieurs plantages successifs du nœud principal du cluster de base de données.
- Observer le comportement des services

En complément, d'autres pistes sont à l'étude, comme la modification de la configuration de [la stratégie de connexion sur Mysql router](#). Aujourd'hui, nous utilisons la stratégie "round-robin" à la fois pour les connexions RW et RO. Il pourrait être intéressant de tester les stratégies "first-available" pour l'interface RW et "round-robin-with-fallback" pour l'interface RO.

Plusieurs mesures préventives peuvent cependant être mises en place pour réduire le temps d'intervention et ainsi limiter la durée d'indisponibilité :

- Vérifier les logs de tous les composants remontés sur datadog. Cette mesure a plusieurs objectifs
 - Envoyer uniquement des logs pertinents pour éviter d'être noyés d'informations superflues
 - Configurer des alertes de vélocité sur des logs d'erreur et/ou de warning
- Mettre en place un protocole de test pour éprouver la connexion entre les différents services et Mysql router (changement de topologie du cluster, load balancing des requêtes,)
- Monitorer les échanges entre services internes pour identifier rapidement les liens défectueux